



# 第三章 词法分析

1. 词法分析的功能
2. 词法分析程序的设计与实现
  - 状态图
3. 词法分析程序的自动生成
  - 有穷自动机



### 3.1 词法分析程序的功能及实现方案

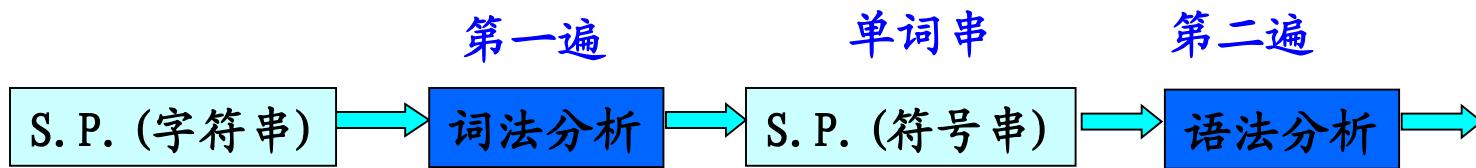
#### ➤ 词法分析程序的功能

- ◆ 词法分析：根据词法规则识别及组合单词，进行词法检查。
- ◆ 对数字常数完成数字字符串到（二进制）数值的转换。
- ◆ 删去空格字符和注解。



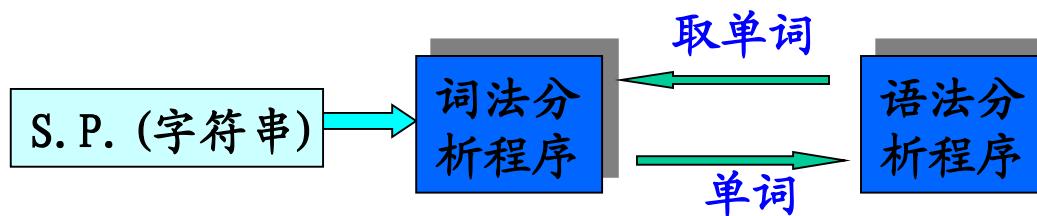
## 实现方案：基本上有两种

### 1. 词法分析单独作为一遍



优点：结构清晰、各遍功能单一  
缺点：效率低

### 2. 词法分析程序作为单独的子程序





## 3.2 单词的种类及词法分析程序的输出形式

### 单词的种类

1. 保留字: begin、end、for、do...
2. 标识符:
3. 常数: 无符号数、布尔常数、字符串常数等
4. 分界符: +、-、\*、/



## 词法分析程序的内部形式

表示单词的种类，可用整数编码或记忆符表示

部形式

不同的单词有不同的值

单词类别	单词值
整型	58
保留字	“for”

几种常用的单词内部形式：

- 1、按单词种类分类
- 2、保留字和分界符采用一符一类
- 3、标识符和常数的单词值可为指示字（指针值）



## 方案1、按单词种类分类

单词名称	类别编码	单词值
------	------	-----

标识符	1	内部字符串
无符号常数(整)	2	整数值
无符号浮点数	3	数值
布尔常数	4	0 或 1
字符串常数	5	内部字符串
保留字	6	保留字或内部编码
分界符	7	分界符或内部编码

## 方案2、保留字和分界符采用一符一类

单词名称	类别编码	单词值
标识符	1	内部字符串
无符号常数(整)	2	整数值
无符号浮点数	3	数值
布尔常数	4	0 或 1
字符串常数	5	内部字符串
BEGIN	6	-
END	7	-
FOR	8	-
DO	9	-
.....	.....	.....
:	20	-
+	21	-
*	22	-
,	23	-
(	.....	--



### 3.3 正则文法和状态图

- 状态图的画法（根据文法画出状态图）

例如：正则文法

$$Z ::= U0 \mid V1$$

$$U ::= Z1 \mid 1$$

$$V ::= Z0 \mid 0$$

左线性文法

$$L(G[Z]) = \{ B^n \mid n > 0 \}, \text{ 其中 } B = \{01, 10\}$$



例：正则文法

$Z ::= U0 | V1$

$U ::= Z1 | 1$

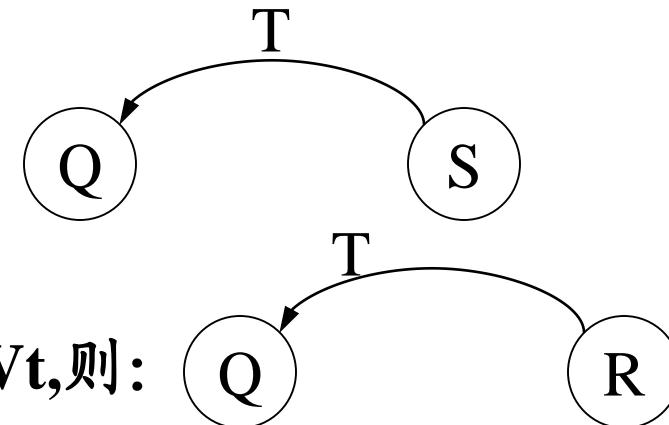
$V ::= Z0 | 0$

## 左线性文法状态图的画法：

1. 令G的每个非终结符都是一个状态；

2. 设一个开始状态S；

3. 若 $Q ::= T$ ,  $Q \in V_n$ ,  $T \in V_t$ , 则:



4. 若 $Q ::= RT$ ,  $Q, R \in V_n$ ,  $T \in V_t$ , 则:

5. 按自动机方法，可加上开始状态和终止状态标志。



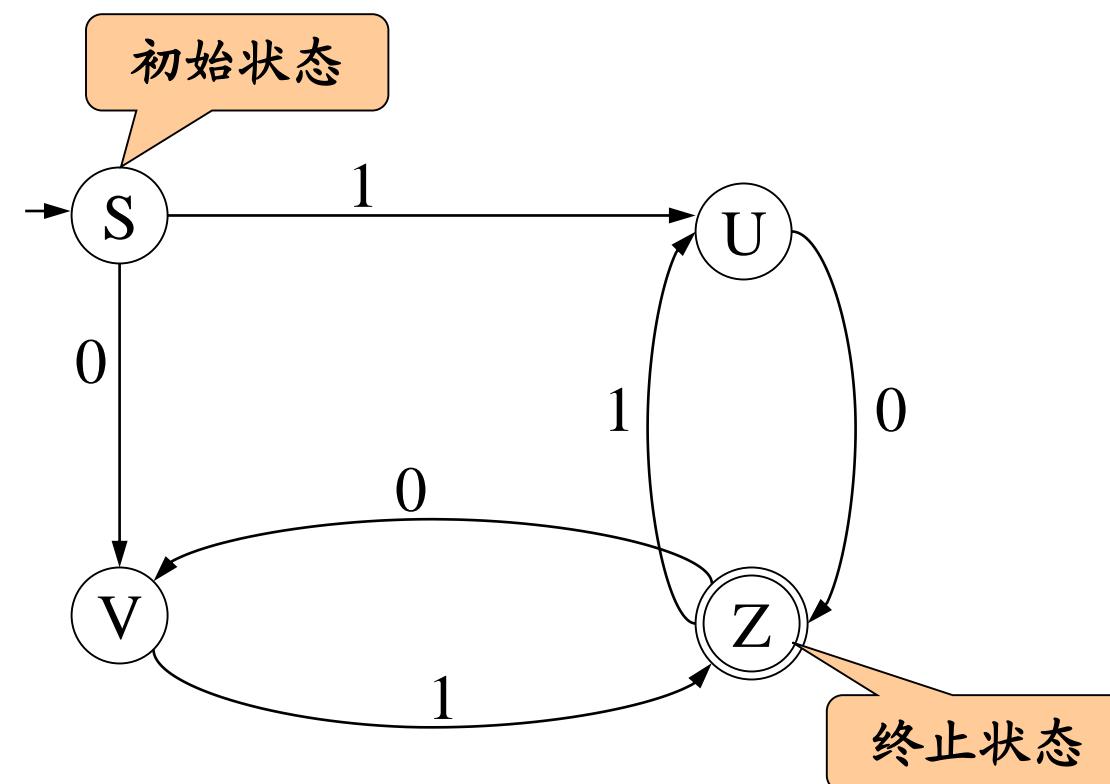
例如：正则文法

$$Z ::= U0 \mid V1$$

$$U ::= Z1 \mid 1$$

$$V ::= Z0 \mid 0$$

其状态图为：





## 识别算法（自然语言描述）

利用状态图可按如下步骤分析和识别字符串x：

1、置初始状态为当前状态，从x的最左字符开始，重  
复步骤2，直到x右端为止。

2、扫描x的下一个字符，在当前状态所射出的弧中找  
出标记有该字符的弧，并沿此弧过渡到下一个状态；

如果找不到标有该字符的弧，那么x不是句子，过  
程到此结束；

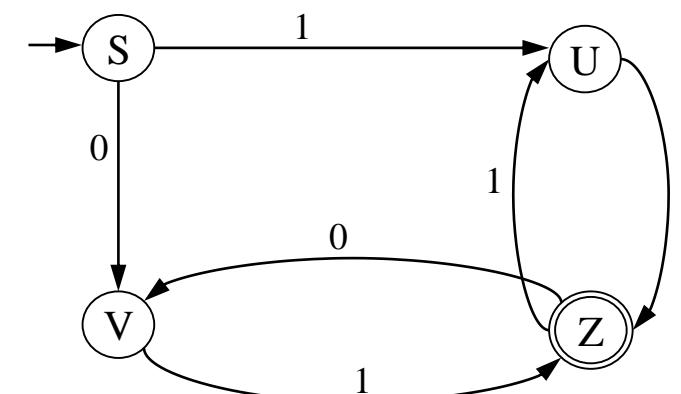
如果扫描的是x的最右端字符，并从当前状态出发  
沿着标有该字符的弧过渡到下一个状态为终止状态Z，  
则x是句子。

例：  $x=01101$  和  $1011$

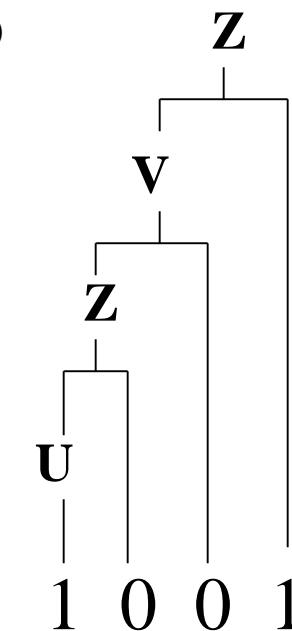


## 问题:

- 1、上述分析过程是属于自底向上分析？还是自顶向下分析？
- 2、怎样确定句柄？



$Z = | \Rightarrow V1 = | \Rightarrow Z01 = | \Rightarrow U001 = | \Rightarrow 1001$





## 3.4 词法分析程序的设计与实现

词法规则 → 状态图 → 词法分析程序



### 3.4.1 文法及其状态图

#### 语言的单词符号

标识符

保留字（标识符的子集）

无符号整数

单分界符 +、 \*、 : 、 , 、 ( 、 )

双分界符 :=

#### 两点说明：

- 1、注释符号 /\* 和 \*/ 以及 //。词法分析程序不输出注释！
- 2、各单词之间用空白符号（空格、制表、回车）分开。



文法: 1. <标识符> ::= 字母 | <标识符>字母 | <标识符>数字

2. <无符号整数> ::= 数字 | <无符号整数>数字

3. <单字符分界符> ::= : | + | \* | , | ( | )

4. <双字符分界符> ::= <冒号> =

5. <冒号> ::= :

6. <注释头符号> ::= <斜竖> \*

7. <斜竖> ::= /

标识符

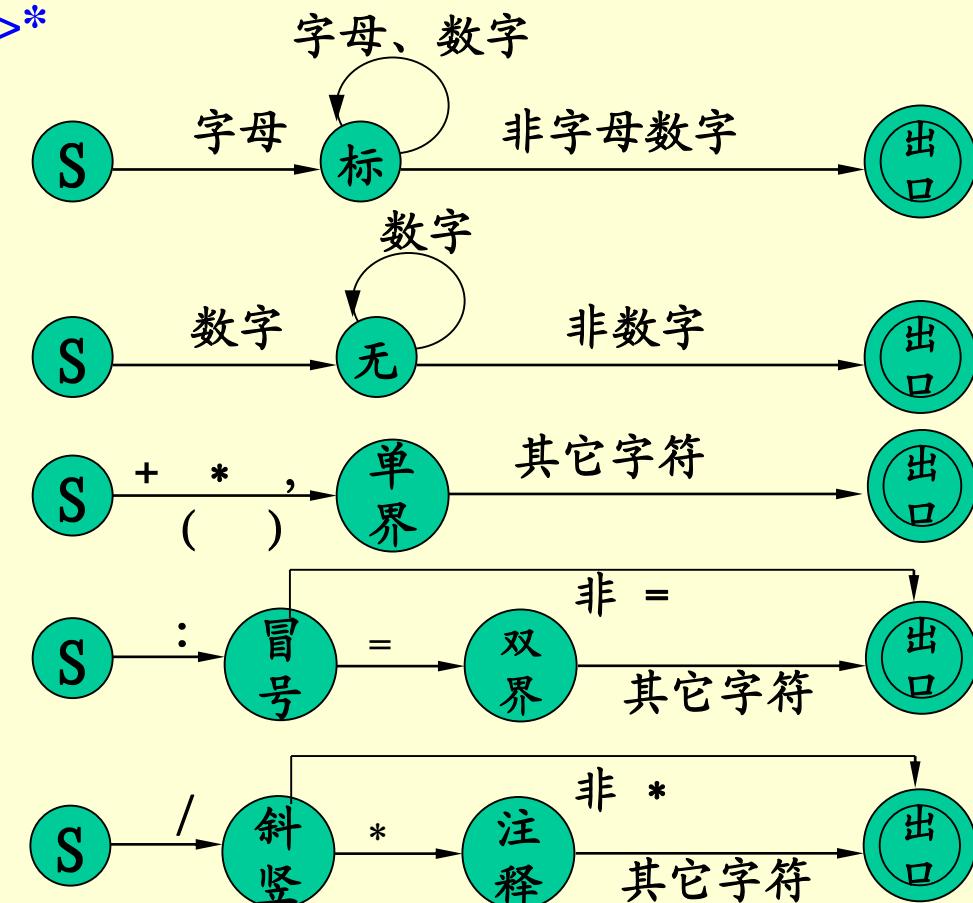
无符号整数

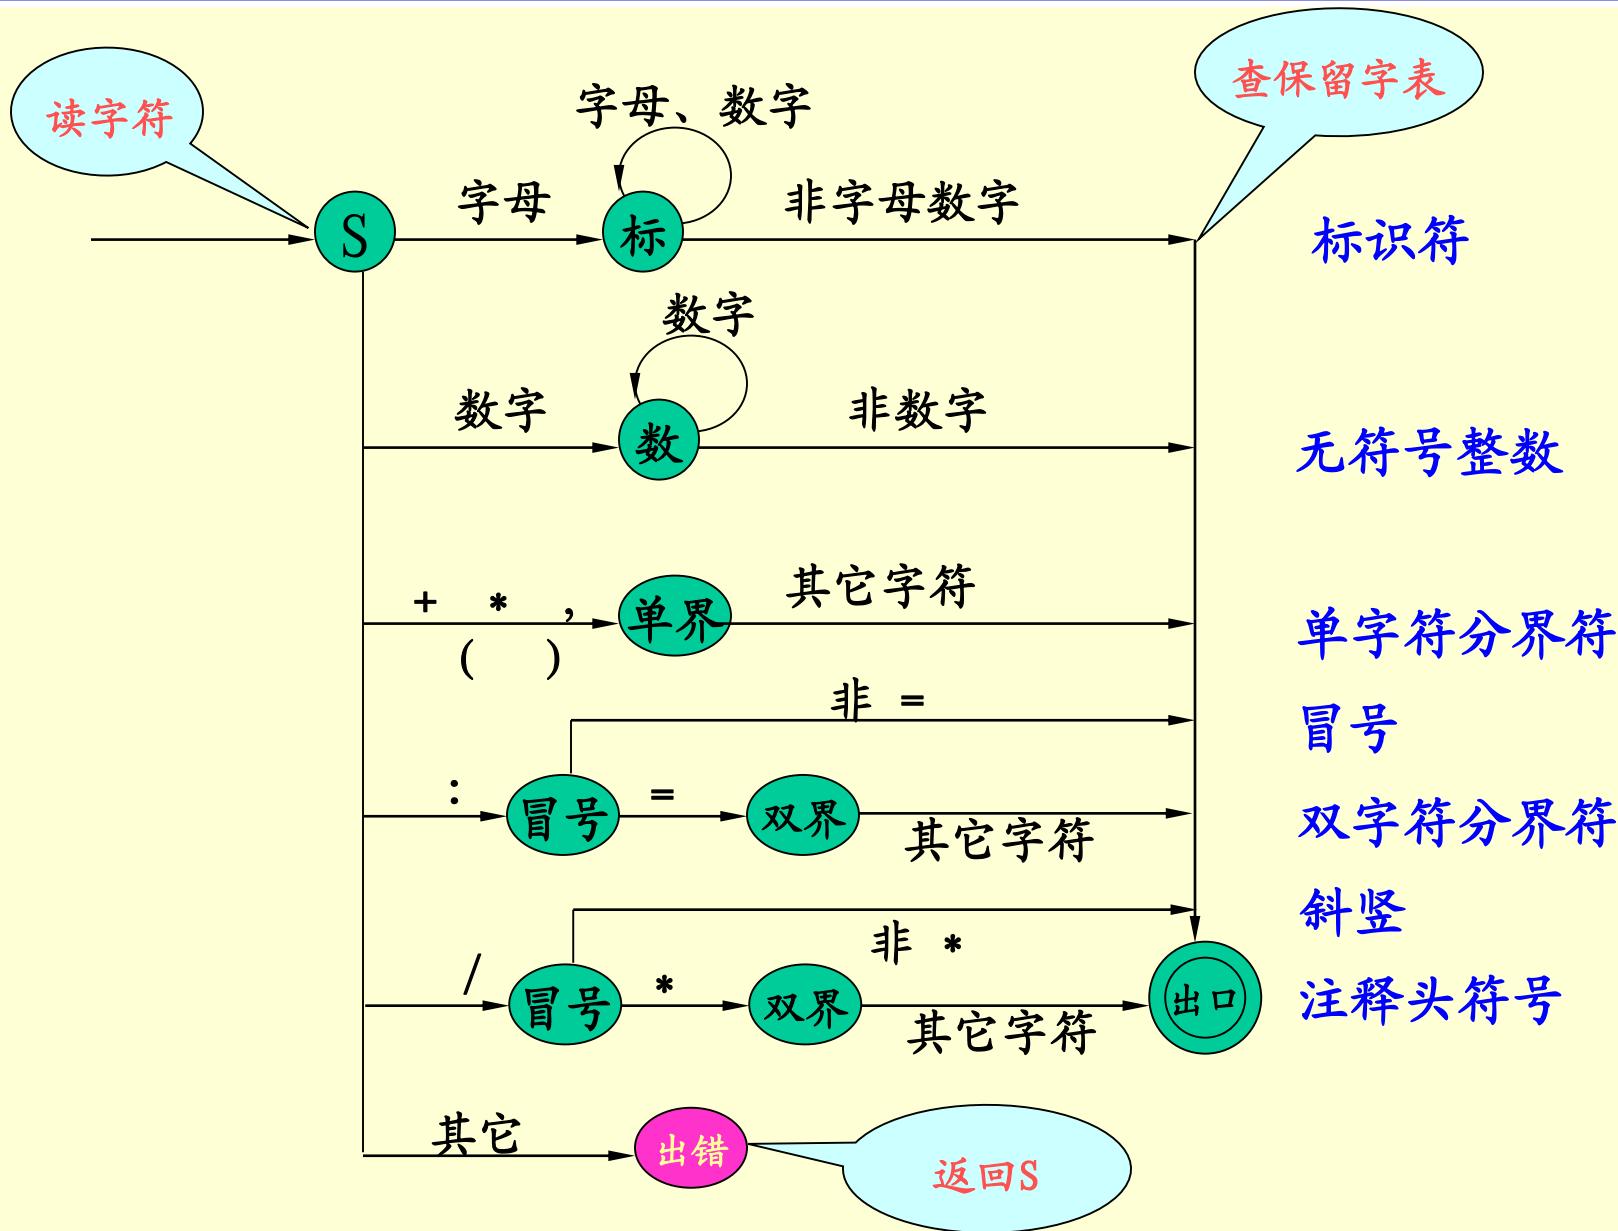
单字符分界符

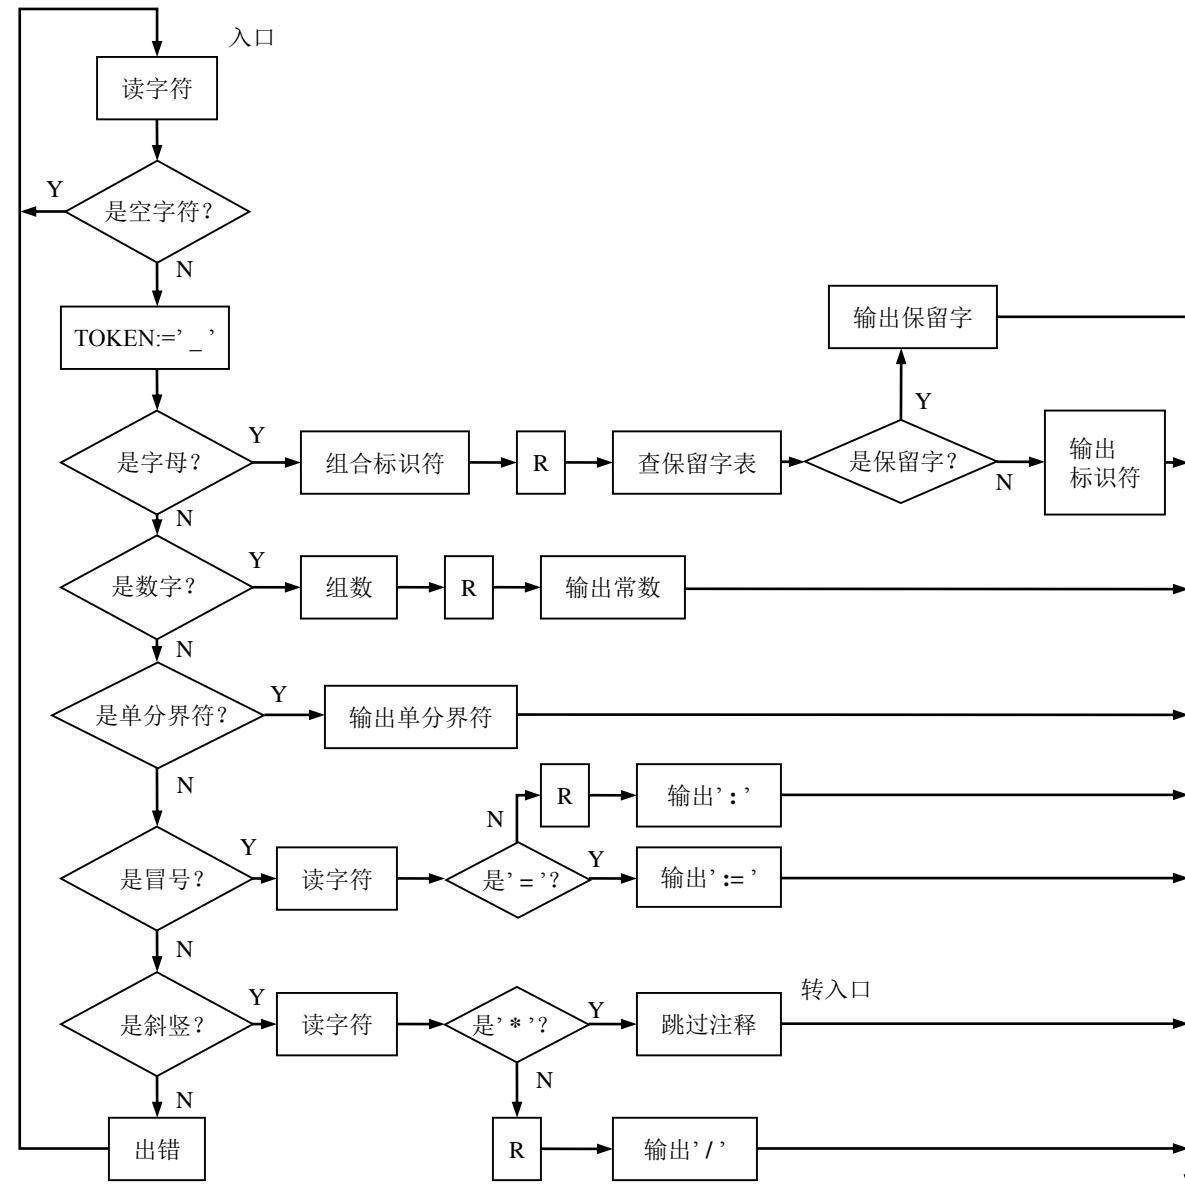
双字符分界符

注释头符号

正则文法!









## 3.4.2 状态图的实现——构造词法分析程序

1. 单词及内部表示

2. 词法分析程序需要引用的公共（全局）变量和过程

3. 词法分析程序算法



## 1. 单词及内部表示：保留字和分界符采用一符一类

单词名称	类别编码	记忆符	单词值
BEGIN	1	BEGINSY	-
END	2	ENDSY	-
FOR	3	FORSY	-
DO	4	DOSY	-
IF	5	IFSY	-
THEN	6	THENSY	-
ELSE	7	ELSESY	-
标识符	8	IDSY	内部字符串
常数(整)	9	INTSY	整数值
:	10	COLONSY	-
+	11	PLUSSY	-
*	12	STARSY	-
,	13	COMSY	-
(	14	LPARSY	-
)	15	RPARSY	-
:=	16	ASSIGNSY	-



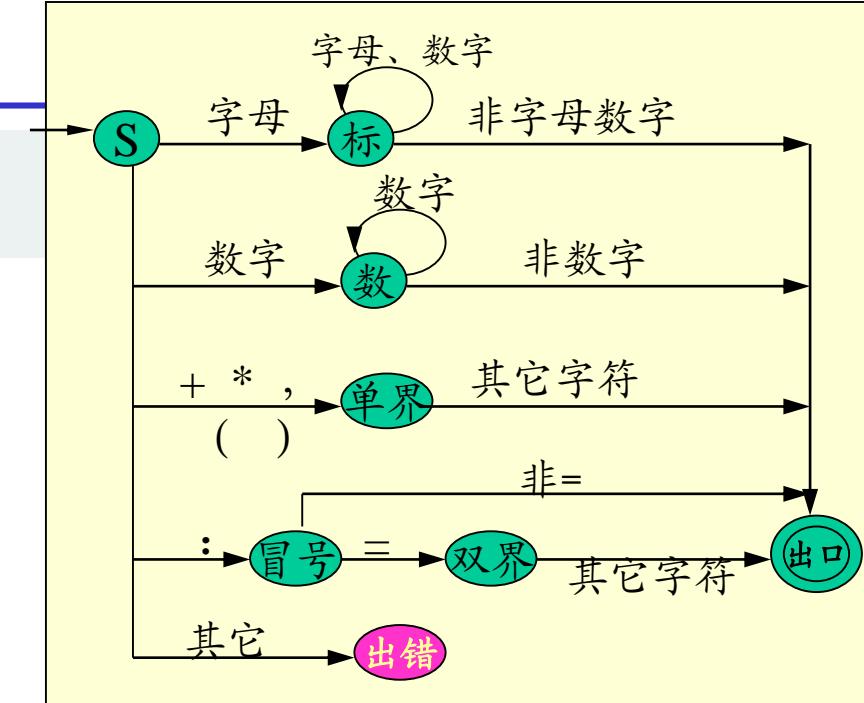
## 2.词法分析程序需要引用的公共（全局）变量和过程

名 称	类 型	功 能
CHAR	字符变量	存放当前读入的字符
TOKEN	字符数组	存放单词字符串
GETCHAR	读字符过程	读字符到CHAR，移动指针
GETNBC	过程	反复调用GETCHAR，直至CHAR进入一个非空白字符
CAT	过程	CHAR与TOKEN连接
ISLETTER 和 ISDIGIT	布尔函数	判断CHAR是字母还是数字
UNGETCH	过程	读字符指针后退一个字符
RESERVE	布尔函数	判断TOKEN中的字符串是保留字，还是标识符
ATOI	函数	字符串到数字的转换
ERROR	过程	出错处理



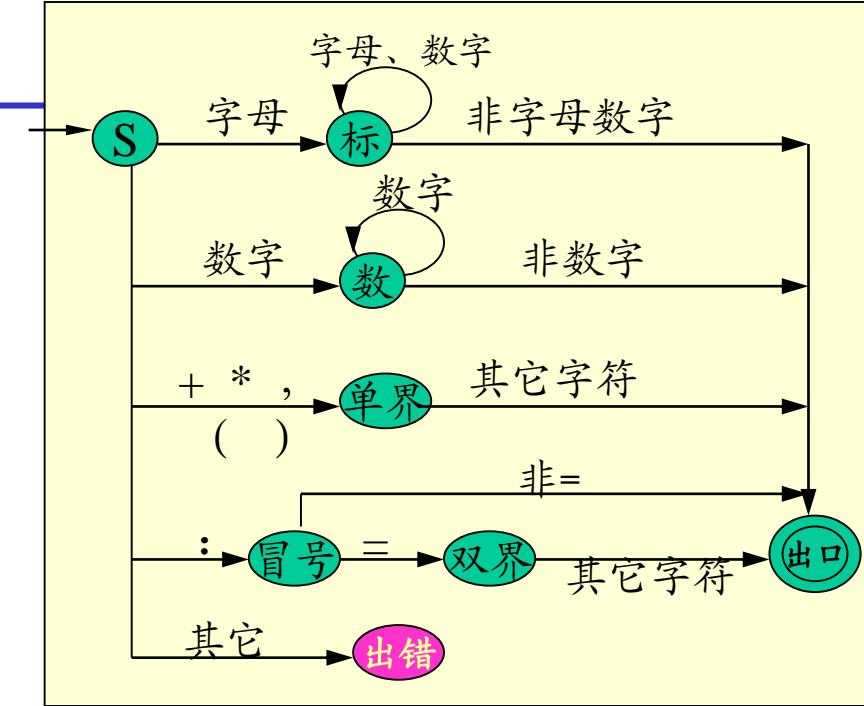
### 3、词法分析程序算法

```
START: TOKEN := ‘ ’; /*置TOKEN为空串*/
       GETNBC; GETCHAR;
CASE CHAR OF
‘A’..‘Z’: BEGIN
      WHILE ISLETTER OR ISDIGIT DO
          BEGIN CAT; GETCHAR; END
      UNGETCH;
      C:= RESERVE;
      IF C=0 THEN RETURN(‘IDSY’, TOKEN)
      ELSE RETURN (C,-); /*C为保留字编码*/
END
‘0’..‘9’: BEGIN
      WHILE ISDIGIT DO
          BEGIN CAT; GETCHAR; END
      UNGETCH;
      RETURN (‘INTSY’,atoi);
END
‘+’: RETURN(‘PLUSSY’,-);
```





```
'*': RETURN('STARSY',-);
',': RETURN('COMMASY',-);
'(': RETURN('LPARSY',-);
')': RETURN('RPARSY',-);
'..': BEGIN
    GETCHAR;
    if CHAR='=' THEN RETURN('ASSIGNSY',-);
    UNGETCH;
    RETURN('COLONSY',-);
END
ERROR;
END OF CASE
GOTO START;
```





```
int getsym() /* 返回类别编码 */
{
    clearToken();
    while (isSpace() || isNewline() || isTab())  getchar(); /* 读取字符，跳过空格、换行和Tab */
    if (isLetter()) /* 判断当前字符是否是一个字母 */
    {
        while (isLetter() || isDigit()) /* 将字符拼接成字符串 */
            { catToken();  getchar(); }
        retract(); /* 指针后退一个字符 */
        int resultValue = reserver(); /* resultValue是查找保留字的返回值 */
        if (resultValue==0)  symbol= IDSY; /* resultValue=0, token中的字符串为标识符 */
        else  symbol= resultValue; /* 否则token中的字符串为保留字 */
    }
    else if (isDigit()) /* 判断当前字符是否是一个数字 */
    {
        while (isDigit()) /* 将字符拼接成整数 */
            { catToken();  getchar(); }
        retract();
        num= transNum(token); /* 将token中的字符串转换成整数 */
        symbol= INTSY; /* 此时识别的单词是整数 */
    }
}
.....
```



## 第三章作业：

P73: 1、2、3 (词法见65-67页)